

08 - Pandas Library I (Deep Dive Edition)

哈尔滨工业大学 黄子扬

2026 年 6 月 6 日

Contents

1	The Core Structures / Pandas 两大核心结构	2
2	Creating DataFrames / 创建表格的多种方式	2
2.1	Using the Constructor / 构造函数详解	2
3	Indexing Slicing / 索引与切片 (期末重点)	2
4	Inspecting Metadata / 查看元数据与统计	3
5	Data Manipulation / 数据结构修改	3
5.1	Inserting and Dropping / 增删列	3
5.2	Conditional Update with .where() / 条件替换	3
5.3	Filtering Labels / 标签过滤	3
6	Combining Data / 数据合并 (Join Merge)	4
7	Aggregation / 数据分组与排序	4
7.1	GroupBy / 分组聚合	4
7.2	Sorting / 排序	4
8	Iteration / 遍历	4

1 The Core Structures / Pandas 两大核心结构

【Concept / 核心概念】1

Series vs. DataFrame / 一维与二维

- **Series**: The 1-dimensional analog of the DataFrame. Think of it as a single column with labels. / **Series** 是 1 维结构，DataFrame 的每一列本质上都是一个 Series [1, 2]。
- **DataFrame**: A tabular representation of data (rows and columns), similar to a spreadsheet or SQL table. It is **size-mutable**. / **DataFrame** 是 2 维表格结构，其大小可动态调整（增删行列）[3]。

【Concept / 核心概念】1

The Peculiarity of Index / 索引的特殊性 In Pandas, **Index** are about **labels**, not just performance (like in SQL). They help with selection and automatic alignment during operations. / 在 Pandas 中，索引是关于“标签”的，它帮助我们在进行两个表格运算时自动对齐数据 [4, 5]。

2 Creating DataFrames / 创建表格的多种方式

2.1 Using the Constructor / 构造函数详解

```
pd.DataFrame(data, index, columns, dtype) [6]
```

- **From Dict**: Keys become column labels; values become column data. / 字典的键变列名 [7]。
- **From List**: Nested lists become rows; you can manually specify **columns** and **index** [8, 9]。
- **From CSV**: Using `pd.read_csv("file.csv")` is the most common way to load large datasets [10]。

3 Indexing Slicing / 索引与切片（期末重点）

【Warning / 避坑指南】1

Label-based (.loc) vs. Position-based (.iloc) 这是初学者最容易混淆的地方，请务必背诵以下区别 [1, 11]:

- **.loc**: Based on **Labels**. Slicing is **INCLUSIVE** of the right boundary.
例: `df.loc['i':'iii']` 会返回包含'iii' 在内的所有行。
- **.iloc**: Based on **Integer Positions**. Slicing is **EXCLUSIVE** of the right boundary (standard Python rule).
例: `df.iloc[0:2]` 只返回第 0 和第 1 行，**不含**第 2 行。

【Example / 深度实操案例】1

Selection Shortcuts / 选择捷径

```
# Column selection
df['A']          # Returns Series
df[['A', 'C']]   # Returns new DataFrame
df.A             # Attribute lookup (works if no spaces) [12]

# Scalar selection (Single values) [13]
df.at[0, 'Name'] # Fast label-based access to a single value
df.iat          # Fast position-based access to a single value
```

4 Inspecting Metadata / 查看元数据与统计

- `df.info()`: Gives index range, column list, non-null counts, and memory usage. / 查看非空值计数和内存占用 [14]。
- `df.describe()`: Summary statistics (mean, std, min, max, percentiles) for **numerical columns only**. / 仅针对数值列生成统计摘要 [14, 15]。
- `df.shape`: Returns a tuple (rows, columns) [16]。

5 Data Manipulation / 数据结构修改

5.1 Inserting and Dropping / 增删列

- **Insert**: `df.insert(loc=2, column="Class", value='A')` 在指定位置插入新列 [17]。
- **Drop**: `df.drop(columns='Age')` 删除冗余列 [18]。

5.2 Conditional Update with `.where()` / 条件替换

【Concept / 核心概念】1

`.where()` Logic `df.where(condition, other=x)`: If the condition is **False**, the value is replaced by **other**. / 如果条件为假，则替换为新值 [18]。

5.3 Filtering Labels / 标签过滤

【Warning / 避坑指南】1

`.filter()` vs. Data Filtering `df.filter(like='N', axis='columns')` applies the filter to the **column labels or row index**, **NOT** the actual data inside. / `.filter()` 过滤的是“名字”，而不是数据内容 [19]。

6 Combining Data / 数据合并 (Join Merge)

【Concept / 核心概念】1

SQL-style Merging / SQL 风格合并 [20, 21] `pd.merge(df1, df2, how='...', on='Name')`

- `how='inner'`: Only keep rows where the 'Name' exists in **BOTH** tables.
- `how='left'`: Keep all rows from df1, fill missing df2 data with NaN.
- `how='outer'`: Keep all rows from both tables.

7 Aggregation / 数据分组与排序

7.1 GroupBy / 分组聚合

【Example / 深度实操案例】1

Split-Apply-Combine / 拆分-应用-组合

```
# Calculate average marks grouped by 'Class'
student_df.groupby('Class').mean() # [22]
```

7.2 Sorting / 排序

```
# Sort by 'Marks' in ascending order (default)
df.sort_values('Marks') # [23]
# Multiple columns sorting
df.sort_values(['salePrice', 'bathrooms'], ascending=[True, False]) # [24]
```

8 Iteration / 遍历

【Concept / 核心概念】1

`.iterrows()` Loop through each row as (index, row) pairs. / 逐行访问每一个元素 [22, 23]。